# LAPORAN FINAL PROJEK
# ARTIFICIAL INTELLIGENCE
# PREDIKSI STRES PADA PENGGUNA MEDIA SOSIAL MENGGUNAKAN LOGISTIC REGRESSION DAN RANDOM FOREST BERBASIS FITUR LINGUISTIK DAN SOSIAL

Dosen Pengampu:
Riskyana Dewi Intan P, M.Kom.
Yuni Rosita Dewi, S.Si., M.Si.


Oleh Kelompok 7:

| | |
|---|---|
| Nadine Putri Aulia | (24031554094) |
| Adisti Eka Nabila | (24031554119) |
| Cintiya Agustin Nareswari | (24031554218) |

**PROGRAM STUDI S1 SAINS DATA**
**FAKULTAS PENDIDIKAN DAN ILMU PENGETAHUAN ALAM**
**UNIVERSITAS NEGERI SURABAYA SURABAYA**

**2025**

# BAB II
# PENDAHULUAN

## 1.1 Latar Belakang

Media sosial telah menjadi sarana utama bagi individu untuk mengekspresikan perasaan, emosi, serta kondisi psikologis melalui teks secara terbuka. Unggahan dan komentar pengguna sering mengandung pola bahasa, pilihan kata, serta ekspresi emosional yang mencerminkan kondisi mental, termasuk stres dan depresi. Oleh karena itu, data media sosial memiliki potensi besar untuk dimanfaatkan sebagai sumber informasi dalam analisis kesehatan mental secara tidak langsung dan berskala luas (Ayyalasomayajula et al., 2024).

Sejumlah penelitian menunjukkan bahwa pendekatan machine learning mampu digunakan untuk mendeteksi kondisi psikologis, seperti stres dan depresi, berdasarkan fitur linguistik yang terkandung dalam teks media sosial. Fitur-fitur linguistik tersebut mencakup emosi positif dan negatif, kompleksitas bahasa, serta penggunaan lexicon tertentu yang berkaitan dengan kondisi emosional pengguna (Geetha et al., 2020). Analisis fitur linguistik ini menjadi penting karena bahasa yang digunakan seseorang sering kali mencerminkan keadaan psikologis yang sedang dialaminya.

Selain fitur linguistik, karakteristik interaksi sosial pengguna di media sosial juga berpotensi memengaruhi tingkat stres. Fitur sosial media seperti karma, rasio upvote, dan jumlah komentar dapat menggambarkan tingkat respons sosial serta keterlibatan pengguna terhadap konten yang dibagikan. Informasi ini dinilai dapat memberikan kontribusi tambahan dalam memprediksi tingkat stres pengguna, sehingga perlu dianalisis secara bersamaan dengan fitur linguistik (Ayyalasomayajula et al., 2024).

Dalam konteks pemodelan, pemilihan algoritma machine learning memiliki peranan penting dalam menentukan performa prediksi. Logistic Regression merupakan algoritma klasifikasi yang banyak digunakan karena kesederhanaan dan kemampuannya dalam menjelaskan hubungan antara fitur dan label. Namun, performa Logistic Regression sangat dipengaruhi oleh skala data, sehingga penerapan metode scaling menjadi faktor penting dalam meningkatkan kinerja model (Ahsan et al., 2021). Di sisi lain, Random Forest merupakan algoritma ensemble yang mampu menangani data berdimensi tinggi serta hubungan non-linear antar fitur, serta relatif tidak sensitif terhadap perbedaan skala data (Pudjianto & Hidayat, 2024).

Berdasarkan permasalahan tersebut, penelitian ini dilakukan untuk menganalisis pengaruh fitur linguistik dan fitur sosial media terhadap tingkat stres pengguna media sosial, serta membandingkan performa algoritma Logistic Regression dan Random Forest dalam melakukan prediksi stres. Selain itu, penelitian ini juga bertujuan untuk mengidentifikasi kategori fitur yang paling berpengaruh terhadap prediksi tingkat stres melalui analisis feature importance menggunakan model Random Forest classifier.

## 1.2 Rumusan Masalah

1. Bagaimana pengaruh fitur linguistik seperti emosi, kompleksitas bahasa, dan pengaruh lexicon tertentu terhadap tingkat stres pengguna media sosial berdasarkan nilai label?
2. Seberapa besar kontribusi fitur sosial media, seperti karma, upvote ratio, dan jumlah komentar dalam memprediksi tingkat stres?
3. Model prediksi mana yang memiliki performa terbaik, apakah Logistic Regression atau Random Forest classifier, dalam memprediksi tingkat stres berdasarkan fitur linguistik dan sosial media?

4. Fitur kategori mana yang paling berpengaruh, apakah fitur linguistik atau fitur sosial media, berdasarkan hasil feature importance dari model Random Forest classifier?

**1.3 Tujuan**

1. Menganalisis pengaruh fitur linguistik seperti emosi, kompleksitas bahasa, dan lexicon terhadap tingkat stres pengguna media sosial.
2. Mengukur kontribusi fitur sosial media seperti karma, upvote ratio, dan jumlah komentar dalam memprediksi tingkat stres.
3. Membandingkan performa model Logistic Regression dan Random Forest classifier dalam memprediksi tingkat stres berdasarkan kombinasi fitur linguistic dan sosial.
4. Mengidentifikasi fitur yang paling berpengaruh terhadap prediksi tingkat stres berdasarkan nilai feature importance dari model Random Forest classifier.

# BAB II
# TINJAUAN PUSTAKA

## 2.1 Media Sosial & Stres

Media sosial menjadi sarana utama bagi individu untuk mengekspresikan pikiran, emosi, dan pengalaman melalui teks. Pada platform berbasis teks seperti Reddit, pengguna cenderung menuliskan perasaan secara terbuka dan anonim, sehingga bahasa yang digunakan dapat merefleksikan kondisi psikologis, termasuk tingkat stres. Penelitian sebelumnya menunjukkan bahwa pola bahasa pada media sosial memiliki keterkaitan dengan kondisi stres dan depresi, sehingga data media sosial dapat dimanfaatkan sebagai sumber informasi untuk analisis kesehatan mental berbasis pembelajaran mesin (Geetha et al., 2020).

Dalam penelitian ini, media sosial digunakan sebagai sumber data untuk memprediksi tingkat stres pengguna berdasarkan fitur linguistik dan sosial. Data yang dianalisis berupa fitur numerik hasil ekstraksi bahasa, seperti emosi, struktur linguistik, serta karakteristik sosial pengguna, yang kemudian diproses menggunakan algoritma Logistic Regression dan Random Forest. Pendekatan ini memungkinkan identifikasi pola stres secara objektif dan terukur, serta mendukung penggunaan media sosial sebagai sarana deteksi dini stres berbasis data (Geetha et al., 2020).

## 2.2 Text Mining

Text mining merupakan proses untuk mengekstraksi informasi bermakna dari data teks dengan mengubahnya ke dalam bentuk numerik yang dapat diproses oleh algoritma pembelajaran mesin. Dalam konteks media sosial, text mining memungkinkan identifikasi pola bahasa yang berkaitan dengan kondisi psikologis pengguna melalui analisis kata, emosi, dan struktur linguistik. Penelitian sebelumnya menunjukkan bahwa fitur hasil text mining dari data media sosial efektif digunakan untuk membangun model klasifikasi stres dan depresi secara otomatis (Ayyalasomayajula et al., 2024).

Pada penelitian ini, text mining tidak dilakukan pada teks mentah secara langsung, melainkan melalui pemanfaatan fitur linguistik dan sosial yang telah diekstraksi menjadi data numerik. Pendekatan ini memungkinkan proses pemodelan yang lebih efisien serta mengurangi kompleksitas pemrosesan teks, tanpa menghilangkan informasi penting yang merepresentasikan kondisi psikologis pengguna. Dengan demikian, text mining berperan sebagai tahap fundamental dalam menghubungkan data media sosial dengan algoritma Logistic Regression dan Random Forest untuk prediksi tingkat stres (Ayyalasomayajula et al., 2024).

.

## 2.3 Fitur Linguistik

Fitur linguistik digunakan untuk merepresentasikan karakteristik bahasa pengguna dalam media sosial yang berkaitan dengan kondisi psikologis. Analisis terhadap fitur linguistik memungkinkan identifikasi pola bahasa yang mencerminkan keadaan emosional dan kognitif pengguna. Penelitian sebelumnya menunjukkan bahwa karakteristik bahasa dalam unggahan media sosial dapat dimanfaatkan untuk mendeteksi kondisi mental seperti stres dan depresi menggunakan pendekatan pembelajaran mesin (Geetha et al., 2020).

Dalam penelitian ini, fitur linguistik digunakan dalam bentuk data numerik hasil ekstraksi bahasa yang telah tersedia pada dataset. Fitur-fitur tersebut dianalisis bersama dengan fitur sosial untuk memprediksi tingkat stres pengguna menggunakan algoritma Logistic Regression dan Random Forest. Pendekatan ini memungkinkan proses pemodelan dilakukan secara objektif dan terukur tanpa melibatkan pemrosesan langsung terhadap teks mentah, serta tetap sejalan dengan pendekatan analisis linguistik pada media sosial yang telah digunakan dalam penelitian sebelumnya (Geetha et al., 2020).

## 2.4 Fitur Sosial

Fitur sosial media merupakan komponen yang merepresentasikan aktivitas dan respons pengguna di platform daring. Fitur ini mencakup jumlah komentar, jumlah upvote, rasion upvote, serta nilai karma yang diperoleh suatu unggahan. Fitur sosial media digunakan untuk menggambarkan bagaimana suatu komen diterima oleh komunitas dan mencerminkan tingkat keterlibatan pengguna.

Pemanfaatan metadata sosial terbukti mampu meningkatkan performa model klasifikasi kondisi mental ketika dikombinasikan dengan fitur tekstual. Pola interaksi sosial, seperti tingkat partisipasi dan respons komunitas, dapat menjadi indikator penting dalam mendeteksi kondisi psikologis pengguna media sosial (Ayyalasomayajula et al., 2024). Selain itu, aktivitas pengguna pada platform daring juga dapat mencerminkan adanya gangguan Kesehatan mental, sehingga data media sosial berpotensi digunakan sebagai sumber informasi dalam prediksi tingkat stress (Geetha et al., 2020).

## 2.5 Machine Learning

Machine learning merupakan cabang kecerdasan buatan yang memungkinkan sistem untuk mempelajari pola dari data dan melakukan prediksi atau klasifikasi tanpa diprogram secara eksplisit. Dalam penelitian ini, machine learning digunakan untuk mengklasifikasikan tingkat stres berdasarkan fitur sosial dan linguistik yang diekstraksi dari data media sosial.

Pendekatan supervised learning banyak digunakan dalam penelitian kesehatan mental karena kemampuannya dalam memetakan hubungan antara fitur dan label kelas. Berbagai algoritma machine learning telah diterapkan dalam penelitian terkait prediksi kondisi mental dan menunjukkan hasil yang efektif dalam mengenali pola stres dari data media sosial (Geetha et al., 2020). Selain itu, perbandingan algoritma seperti Logistic Regression dan Random Forest menunjukkan bahwa pemilihan metode yang tepat sangat memengaruhi performa klasifikasi (Pudjianto & Hidayat, 2024).

## 2.6 Logistic Regression

Logistic Regression merupakan algoritma supervised learning yang umum digunakan untuk tugas klasifikasi biner dengan memodelkan probabilitas suatu data termasuk ke dalam kelas tertentu menggunakan fungsi logistik. Algoritma ini banyak digunakan dalam analisis data teks karena mampu menangani data berdimensi tinggi serta memiliki tingkat interpretabilitas yang baik (Ayyalasomayajula et al., 2024).

1. **Logistic Regression tanpa Scaling (Unscaled)**

   Pada kondisi tanpa scaling, fitur numerik digunakan dalam skala aslinya. Perbedaan rentang nilai antar fitur dapat menyebabkan fitur dengan nilai yang lebih besar memiliki pengaruh dominan dalam proses pembelajaran model. Kondisi ini berpotensi menyebabkan proses optimasi menjadi kurang stabil dan menurunkan performa model, khususnya pada algoritma Logistic Regression yang sensitif terhadap skala fitur (Ahsan et al., 2021). Oleh karena itu, penggunaan Logistic Regression tanpa scaling dilakukan sebagai pembanding untuk menganalisis pengaruh normalisasi data terhadap performa klasifikasi.

2. **Logistic Regression dengan Robust Scaler**

   Robust Scaler merupakan teknik feature scaling yang menggunakan nilai median dan rentang interkuartil dalam proses normalisasi data. Teknik ini dirancang untuk mengurangi pengaruh nilai ekstrem atau outlier yang sering ditemukan pada data media sosial, seperti jumlah komentar dan nilai karma (Ahsan et al., 2021).

   Penerapan Robust Scaler pada Logistic Regression bertujuan untuk meningkatkan stabilitas model dan menghasilkan performa klasifikasi yang lebih konsisten. Dengan mengurangi dampak outlier, model diharapkan dapat mempelajari pola data secara lebih representatif dan meningkatkan akurasi prediksi tingkat stres pengguna (Ahsan et al., 2021).

3. **Perbandingan Unscaled dan Robust Scaler**

   Perbandingan antara Logistic Regression tanpa scaling dan dengan Robust Scaler dilakukan untuk mengevaluasi pengaruh teknik normalisasi terhadap performa model. Penggunaan Robust Scaler diharapkan mampu menghasilkan model yang lebih stabil dibandingkan dengan kondisi tanpa scaling, terutama pada dataset yang memiliki distribusi tidak seimbang dan mengandung outlier (Ahsan et al., 2021).

## 2.7 Random Forest

Random Forest merupakan algoritma *ensemble learning* berbasis *decision tree* yang bekerja dengan menggabungkan banyak pohon keputusan untuk meningkatkan akurasi dan mengurangi *overfitting*. Setiap pohon dibangun menggunakan teknik *bootstrap sampling* serta pemilihan subset fitur secara acak pada setiap node, sehingga menghasilkan model yang lebih robust terhadap noise dan variasi data (Ahsan et al., 2021). Algoritma ini efektif dalam menangani hubungan non-linear dan data berdimensi tinggi, menjadikannya banyak digunakan pada berbagai studi *machine learning*, termasuk analisis data kesehatan mental berbasis media sosial (Geetha et al., 2020).

Dalam konteks prediksi depresi atau stres, Random Forest terbukti memiliki performa yang stabil, khususnya pada dataset yang tidak seimbang. Penerapan *class weighting* membantu model mengurangi bias terhadap kelas mayoritas dan meningkatkan kemampuan klasifikasi kelas minoritas (Pudjianto & Hidayat, 2024). Selain itu, Random Forest mampu menyediakan informasi *feature importance* yang berguna untuk mengidentifikasi fitur linguistik dan sosial yang paling berpengaruh dalam proses prediksi, sehingga mendukung interpretabilitas model pada analisis teks media sosial (Ayyalasomayajula et al., 2024)

# BAB III
# METODOLOGI

## 3.1 Dataset

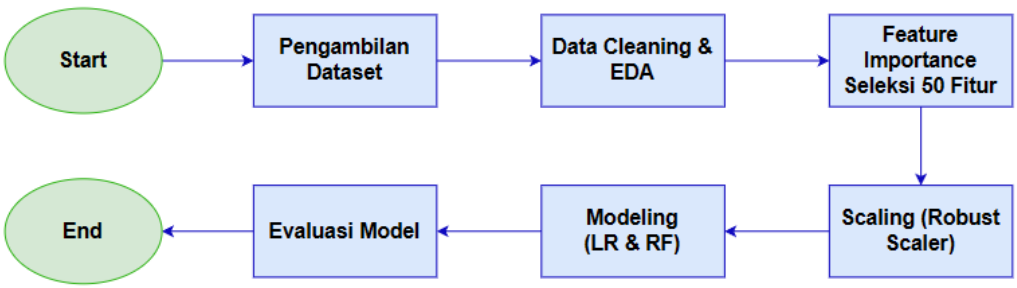
Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle dengan judul *Stress Analysis* yang disusun oleh Shuvojit Das. Dataset ini berasal dari unggahan pengguna media sosial Reddit dan telah diberi label tingkat stres. Setiap data merepresentasikan satu unggahan pengguna yang digunakan sebagai unit analisis dalam penelitian ini (Das, n.d.).

Data pada dataset ini tidak dianalisis dalam bentuk teks mentah. Dataset telah menyediakan fitur numerik hasil ekstraksi dari konten teks dan aktivitas pengguna di media sosial. Oleh karena itu, penelitian ini tidak melakukan proses ekstraksi fitur dari teks secara langsung, melainkan memanfaatkan fitur numerik yang telah tersedia sebagai representasi karakteristik unggahan pengguna.

Fitur-fitur dalam dataset terdiri atas dua kelompok utama. Kelompok pertama adalah fitur linguistik yang merepresentasikan karakteristik bahasa pengguna, seperti aspek emosional, kognitif, dan struktur bahasa yang tercermin dari penggunaan kata dalam unggahan. Kelompok kedua adalah fitur sosial yang menggambarkan karakteristik interaksi pengguna di platform Reddit, seperti tingkat keterlibatan dan respons terhadap unggahan. Pengelompokan fitur ini digunakan untuk merepresentasikan perilaku dan ekspresi pengguna dalam media sosial secara komprehensif.

Selain fitur utama, dataset juga memuat beberapa kolom tambahan berupa informasi identitas unggahan dan metadata. Kolom-kolom tersebut tidak digunakan dalam proses analisis karena tidak berkontribusi langsung terhadap prediksi tingkat stres. Oleh sebab itu, kolom yang tidak relevan dihapus pada tahap pembersihan data agar dataset yang digunakan lebih fokus dan sesuai dengan tujuan penelitian.

## 3.2 Diagram Alur




Penelitian dimulai dengan penggunaan dataset stres pengguna media sosial yang diperoleh dari Kaggle. Dataset ini berisi fitur numerik hasil ekstraksi dari aktivitas dan konten unggahan pengguna Reddit yang telah dilabeli tingkat stres. Dataset tersebut menjadi dasar dalam seluruh proses analisis dan pemodelan.

Tahap selanjutnya adalah *data cleaning* dan *exploratory data analysis (EDA)*. Pada tahap ini dilakukan pembersihan data dengan menghapus atribut yang tidak relevan, pemeriksaan kualitas data, serta analisis awal untuk memahami distribusi label

dan karakteristik fitur. Tahap ini bertujuan memastikan data siap digunakan dalam proses pemodelan dan memberikan gambaran awal mengenai pola yang terdapat dalam dataset.

Setelah data bersih, dilakukan seleksi fitur menggunakan metode *feature importance* berbasis Random Forest. Metode ini digunakan untuk mengidentifikasi fitur-fitur yang memiliki pengaruh paling besar terhadap prediksi tingkat stres. Berdasarkan hasil tersebut, dipilih 50 fitur terbaik yang selanjutnya digunakan sebagai input pada tahap pemodelan.

Sebelum proses pemodelan, data dilakukan normalisasi menggunakan *Robust Scaler* untuk mengurangi pengaruh outlier dan menjaga kestabilan nilai fitur. Pemodelan kemudian dilakukan menggunakan dua algoritma klasifikasi, yaitu Logistic Regression dan Random Forest, untuk membangun model prediksi tingkat stres.

Tahap akhir adalah evaluasi model. Setiap model dievaluasi menggunakan metrik accuracy, precision, recall, dan F1-score. Hasil evaluasi digunakan untuk membandingkan kinerja model sehingga dapat ditentukan model yang paling optimal dalam memprediksi tingkat stres pengguna media sosial. Setelah proses evaluasi dan perbandingan selesai, penelitian diakhiri dengan penarikan kesimpulan berdasarkan hasil yang diperoleh.

## 3.3 Data Cleaning

Tahap data cleaning dilakukan untuk memastikan dataset berada dalam kondisi bersih, konsisten, dan layak digunakan dalam proses analisis dan pemodelan. Data cleaning bertujuan untuk mengurangi noise serta menghilangkan data yang tidak relevan.

Data cleaning yang dilakukan meliputi:

- Pemeriksaan missing values
- Pemeriksaan data duplikat
- Penghapusan kolom yang tidak relevan, seperti identitas unggahan dan teks mentah
- Penyesuaian nama kolom agar lebih ringkas dan mudah dipahami.

Tahap data ini memastikan bahwa dataset hanya berisi fitur-fitur yang relevan dan siap diguakan pada tahap analisis data dan pemodelan.

## 3.4 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset sebelum proses pemodelan. Tahap ini bertujuan untuk mengidentifikasi pola, distribusi data, hubungan antar variabel, serta potensi anomali yang dapat memengaruhi performa model.

### 3.4.1 Statistika Deskriptif

Statistik deskriptif digunakan untuk menggambarkan karakteristik dasar data numerik, seperti nilai minimum, maksimum, rata-rata, dan standar deviasi. Analisis ini memberikan gambaran awal mengenai sebaran data pada setiap fitur linguistik dan sosial media.

### 3.4.2 Deteksi Outlier

Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR) pada seluruh filter numerik. Metode ini digunakan untuk mengidentifikasi nilai ektrem yang berada di luar rentang normal data.

Outlier banyak ditemukan pada fitur sosial media seperti karma dan jumlah komentar, yang secara alami memiliki distribusi tidak seimbang. Hasil deteksi outlier divisualisasikan untuk menunjukkan fitur-fitur dengan jumlah outlier terbanyak. Analisis ini menjadi dasar dalam pemilihan metode scaling yang sesuai pada tahap selanjutnya.

### 3.4.3 Distribusi Label

Analisis distribusi label dilakukan untuk mengetahui proporsi data pada masing-masing kategori tingkat stres. Visualisasi distribusi label digunakan untuk mengidentifikasi apakah dataset berada dalam kondisi seimbang atau tidak seimbang.

Hasil analisis distribusi label menunjukkan adanya perbedaan jumlah data antar kelas, sehingga diperlukan perhatian khusus dalam pemilihan metrik evaluasi model.

### 3.4.4 Korelasi Fitur terhadap Target

Analisis korelasi dilakukan untuk mengetahui hubungan antara setiap fitur dengan variabel target (label tingkat stres). Nilai korelasi digunakan sebagai awal fitur-fitur yang berpotensi berpengaruh terhadap prediksi tingkat stres. Hasil analisis korelasi divisualisasikan dalam bentuk heatmap untuk memudahkan interpretasi hubungan antar variabel.

## 3.5 Pemilihan Fitur

Pada tahap pemilihan fitur, dataset dipisahkan menjadi variabel fitur (X) dan variabel target (y). Variabel target (label) merepresentasikan kelas yang akan diprediksi, sedangkan seluruh kolom selain label digunakan sebagai fitur input. Random Forest digunakan sebagai metode embedded feature selection, yaitu pemilihan fitur yang dilakukan bersamaan dengan pelatihan model. Model dikonfigurasi dengan 300 pohon keputusan (n_estimators=300) dan class_weight="balanced" untuk meningkatkan stabilitas serta menangani ketidakseimbangan kelas. Setelah dilatih, Random Forest secara otomatis menghitung feature importance, yaitu kontribusi masing-masing fitur dalam mengurangi impurity di node pohon keputusan.

Nilai feature importance kemudian diurutkan dari yang paling berpengaruh hingga yang paling rendah, dan 20 fitur teratas divisualisasikan menggunakan grafik batang. Visualisasi ini memudahkan identifikasi fitur-fitur linguistik dan sosial yang paling relevan terhadap prediksi label, serta dapat menjadi dasar analisis lebih lanjut atau penyederhanaan model dengan mempertahankan fitur-fitur yang paling informatif.

## 3.6 Modelling

### 3.6.1 Memilih 50 Fitur Terbaik

Berdasarkan hasil feature importance dari model Random Forest, dipilih 50 fitur teratas yang memiliki kontribusi paling signifikan terhadap proses

klasifikasi. Pemilihan fitur ini bertujuan untuk mengurangi dimensi data sekaligus mempertahankan informasi yang paling relevan terhadap variabel target.

Dataset kemudian dibentuk ulang hanya dengan menyertakan 50 fitur terpilih beserta label kelas, sehingga menghasilkan representasi data yang lebih ringkas dan informatif. Pendekatan ini diharapkan dapat meningkatkan efisiensi komputasi dan mengurangi potensi noise dari fitur yang kurang berpengaruh, tanpa mengorbankan kinerja model dalam memprediksi tingkat stres atau depresi pengguna.

### 3.6.2 Logistic Regression Clasifier

Logistic Regression digunakan sebagai metode klasifikasi untuk memprediksi label berdasarkan kombinasi fitur terpilih. Pada tahap awal, data dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan teknik *train-test split*. Parameter stratify diterapkan pada variabel target untuk menjaga proporsi kelas pada data latih dan data uji, sehingga distribusi kelas tetap seimbang dan hasil evaluasi model menjadi lebih representatif.

Model Logistic Regression dikonfigurasikan dengan max_iter=1000 untuk memastikan proses optimasi konvergen, serta class_weight='balanced' guna mengatasi ketidakseimbangan kelas pada data. Model ini memanfaatkan hubungan linier antara fitur dan probabilitas kelas, sehingga cocok digunakan sebagai *baseline model* dalam penelitian prediksi stres atau depresi.

1. Logistic Regression Clasifier dengan Robust Scaler

   Pada pendekatan ini, sebelum proses pelatihan model Logistic Regression, data fitur terlebih dahulu dinormalisasi menggunakan *Robust Scaler*. Metode *Robust Scaling* dipilih karena lebih tahan terhadap *outlier*, dengan melakukan penskalaan berdasarkan median dan *interquartile range (IQR)*. Pendekatan ini sangat relevan untuk data berbasis linguistik dan sosial yang umumnya memiliki distribusi tidak normal dan nilai ekstrem. Data latih digunakan untuk menyesuaikan parameter skaler (fit_transform), sedangkan data uji hanya ditransformasikan (transform) untuk mencegah *data leakage*. Setelah proses penskalaan, model Logistic Regression dilatih menggunakan data yang telah dinormalisasi dan digunakan untuk memprediksi label pada data uji. Pendekatan ini bertujuan untuk meningkatkan stabilitas dan performa model Logistic Regression, khususnya dalam menangani fitur dengan skala yang berbeda-beda.

2. Logistic Regression Clasifier Tanpa Robust Scaler

   Sebagai pembanding, Logistic Regression juga dilatih menggunakan data fitur tanpa proses penskalaan. Model ini menggunakan konfigurasi parameter yang sama, termasuk max_iter=1000 dan class_weight='balanced'. Pendekatan ini bertujuan untuk mengevaluasi pengaruh *feature scaling* terhadap kinerja Logistic Regression, sehingga dapat dianalisis apakah proses normalisasi memberikan peningkatan performa yang signifikan dibandingkan penggunaan data mentah.

### 3.6.3 Random Forest

Random Forest digunakan sebagai metode klasifikasi berbasis ensemble learning, yaitu menggabungkan banyak pohon keputusan untuk menghasilkan prediksi yang lebih stabil dan akurat. Model ini dikonfigurasikan dengan 300 pohon keputusan (n_estimators=300) untuk meningkatkan kemampuan generalisasi dan mengurangi varians prediksi. Parameter class_weight='balanced' diterapkan untuk menangani ketidakseimbangan kelas, sehingga setiap kelas memberikan kontribusi yang seimbang dalam proses pelatihan.

Berbeda dengan Logistic Regression, Random Forest tidak memerlukan penskalaan fitur karena bekerja berdasarkan pemisahan node pada pohon keputusan. Model dilatih menggunakan data latih dan kemudian digunakan untuk memprediksi label pada data uji. Dalam penelitian ini, Random Forest digunakan sebagai model pembanding non-linier, untuk mengevaluasi kinerja prediksi terhadap Logistic Regression, terutama pada data yang memiliki hubungan kompleks antar fitur.

### 3.6.4 Prediksi

Pada tahap selanjutnya, hasil prediksi dari masing-masing model dikompilasikan ke dalam sebuah *dataframe* untuk memudahkan analisis dan perbandingan performa. Dataframe df_pred memuat label sebenarnya (y_true) serta hasil prediksi dari tiga pendekatan model, yaitu Logistic Regression dengan Robust Scaler (y_pred_lr), Logistic Regression tanpa scaling (y_pred_lr2), dan Random Forest (y_pred_rf). Penyusunan tabel ini bertujuan untuk melakukan evaluasi secara langsung terhadap kesesuaian prediksi model dengan label aktual pada data uji.

Melalui perbandingan baris demi baris, dapat diamati perbedaan perilaku masing-masing model dalam mengklasifikasikan data. Ketidaksesuaian antara y_true dan nilai prediksi menunjukkan terjadinya kesalahan klasifikasi (*misclassification*), yang dapat dianalisis lebih lanjut untuk mengetahui pola kesalahan model. Pendekatan ini memungkinkan identifikasi model yang lebih konsisten dalam memprediksi kelas minoritas maupun mayoritas, serta menjadi dasar untuk evaluasi kuantitatif menggunakan metrik seperti akurasi, precision, recall, dan F1-score pada tahap selanjutnya.

## 3.5 Evaluasi Model

Evaluasi model dilakukan untuk menilai kinerja algoritma klasifikasi dalam memprediksi tingkat stres pengguna media sosial berdasarkan label biner, yaitu 0 (tidak stres) dan 1 (stres). Proses evaluasi bertujuan untuk mengetahui sejauh mana model mampu memberikan prediksi yang akurat serta membandingkan performa antara metode Logistic Regression dan Random Forest yang digunakan dalam penelitian ini.

### 3.5.1 Metode Evaluasi

Evaluasi model dilakukan menggunakan data uji (test set) yang dipisahkan dari data latih (training set) dengan perbandingan 80% data latih dan 20% data uji. Pembagian data dilakukan secara stratified, sehingga proporsi kelas stres dan tidak stres tetap seimbang pada kedua subset data.

Model dilatih menggunakan data latih dan kemudian diuji pada data uji yang belum pernah dilihat sebelumnya. Pendekatan ini bertujuan untuk mengukur kemampuan generalisasi model terhadap data baru sekaligus mengurangi risiko overfitting, sehingga kinerja model pada data nyata dapat lebih akurat dan dapat diandalkan.

### 3.5.2 Metrik Evaluasi

Kinerja model evaluasi menggunakan beberapa metrik evaluasi klasifikasi, yaitu:

1. Accuracy
   Accuracy mengukur proporsi prediksi yang benar terhadap seluruh jumlah data uji. Metrik ini memberikan gambaran umum mengenai tingkat ketepatan model dalam melakukan klasifikasi.
2. Precision
   Precision menunjukkan seberapa besar proporsi prediksi stres yang benar dibandingkan dengan seluruh data yang diprediksi sebagai stres. Metrik ini penting untuk mengukur tingkat kesalahan positif palsu (false positive).
3. Recall
   Recall mengukur kemampuan model dalam mengidentifikasi seluruh data yang benar-benar termasuk dalam kelas stres. Metrik ini menunjukkan seberapa baik model dalam mendeteksi pengguna yang mengalami stres.
4. F1-Score
   F1-Score merupakan rata-rata harmonik antara precision dan recall. Metrik ini digunakan untuk memberikan evaluasi yang lebih seimbang, terutama ketika distribusi kelas tidak sepenuhnya seimbang.

### 3.5.3 Confusion Matrix

Selain menggunakan metrik evaluasi numerik, penelitian ini juga menggunakan confusion matrix untuk menganalisis hasil prediksi model secara lebih rinci. Confusion matrix digunakan untuk menunjukkan jumlah prediksi benar dan salah pada masing-masing kelas, yaitu kelas stres dan tidak stres. Melalui confusion matrix, dapat diketahui jenis kesalahan yang dilakukan oleh model, seperti:

- Prediksi pengguna stres sebagai tidak stres (*false negative*)
- Prediksi pengguna tidak stres sebagai stres (*false positive*)

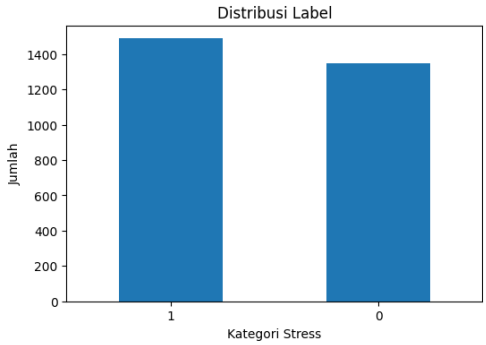
Visualisasi confusion matrix juga membantu dalam memahami pola kesalahan yang dilakukan oleh setiap model secara lebih intuitif

# BAB 4
# HASIL DAN PEMBAHASAN

## 4.1 Eksplorasi Data (EDA)

Dataset yang digunakan dalam penelitian ini terdiri dari 2.838 data dengan 111 atribut, yang mencakup 1 variabel target (label stres) dan 110 fitur linguistik serta sosial. Seluruh fitur berbentuk numerik, sehingga tidak diperlukan proses konversi tipe data tambahan sebelum analisis lebih lanjut.

### 4.1.1 Distribusi Label Stres




Berdasarkan hasil visualisasi distribusi label, dari total 2.838 data, mayoritas data berada pada label stres (1), sementara sisanya berada pada label tidak stres (0). Selisih jumlah antara kedua kelas relatif kecil, sehingga proporsi data tidak didominasi oleh satu kelas tertentu.

Kondisi distribusi seperti ini menunjukkan bahwa dataset cukup seimbang untuk digunakan dalam klasifikasi tingkat stres. Artinya, model tidak akan cenderung hanya mempelajari satu kelas saja, melainkan dapat mengenali pola linguistik dan sosial baik pada pengguna yang mengalami stres maupun yang tidak. Dengan distribusi label yang hampir seimbang, hasil evaluasi model pada tahap selanjutnya dapat dianggap lebih representatif terhadap kondisi data sebenarnya.

### 4.1.2 Deteksi Outlier

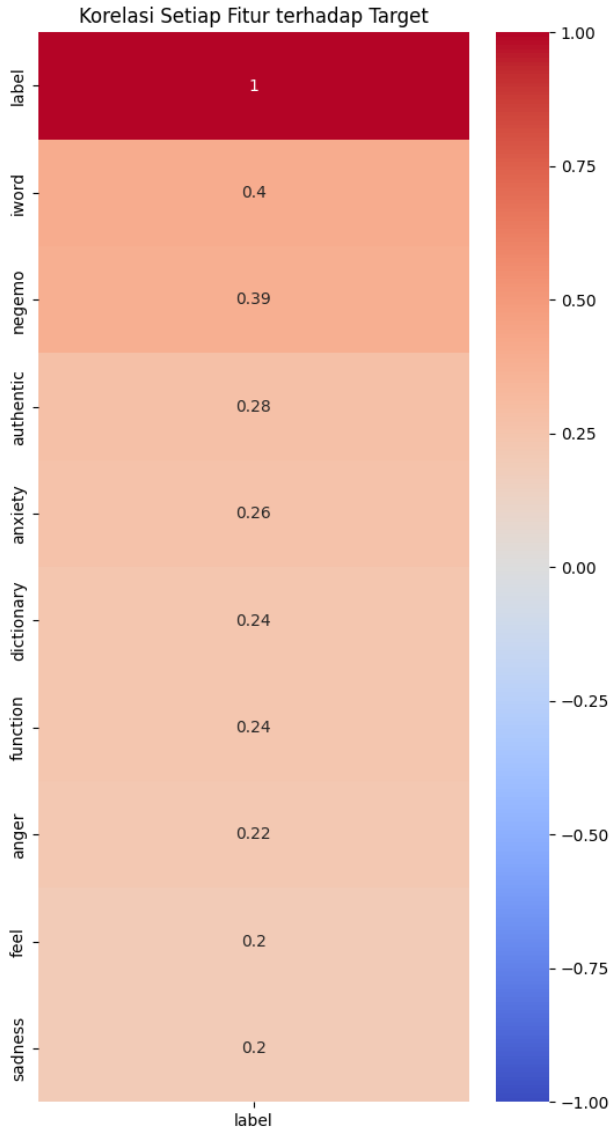



Deteksi outlier dilakukan pada seluruh fitur numerik menggunakan metode Interquartile Range (IQR). Metode ini digunakan untuk mengidentifikasi nilai-nilai ekstrem yang berada di luar rentang kuartil pertama (Q1) dan kuartil ketiga (Q3). Hasil deteksi menunjukkan bahwa sejumlah fitur memiliki jumlah outlier yang cukup tinggi.

Fitur dengan jumlah outlier terbanyak antara lain qmark (632 data), dash (574 data), ingest (520 data), imagerymax (496 data), dan netspeak (447 data). Fitur-fitur tersebut berkaitan dengan penggunaan tanda baca, gaya bahasa informal, serta karakteristik linguistik tertentu dalam teks pengguna media sosial. Banyaknya outlier pada fitur-fitur ini menunjukkan adanya perbedaan intensitas ekspresi bahasa antar pengguna, seperti penggunaan tanda tanya, simbol, dan kata-kata informal secara berlebihan pada sebagian unggahan.

Keberadaan outlier pada penelitian ini tidak dihapus, karena nilai ekstrem tersebut merepresentasikan variasi perilaku berbahasa pengguna media sosial yang justru relevan dalam mendeteksi stres. Oleh karena itu, untuk meminimalkan pengaruh outlier terhadap pemodelan, digunakan metode Robust Scaler pada tahap normalisasi data, khususnya pada algoritma Logistic Regression.

### 4.1.3 Korelasi Fitur Terhadap Label Stres




Hasil analisis korelasi menunjukkan bahwa fitur linguistik memiliki hubungan yang lebih nyata dengan label stres dibandingkan fitur lainnya. Fitur *iword* (korelasi 0,40) dan *negemo* (0,39) menjadi dua fitur dengan hubungan

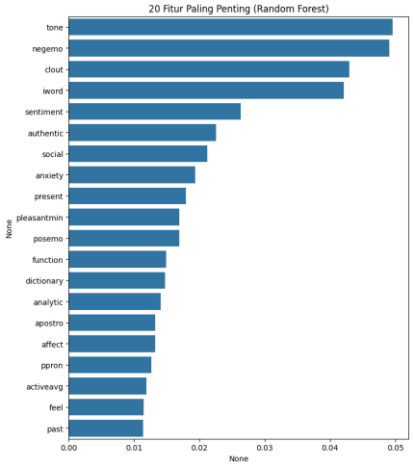
paling kuat terhadap stres. Hal ini menunjukkan bahwa pengguna yang mengalami stres cenderung menulis unggahan yang lebih berfokus pada diri sendiri serta mengekspresikan emosi negatif secara eksplisit. Pola ini menggambarkan kondisi psikologis pengguna yang sedang tertekan, di mana perhatian tertuju pada pengalaman personal dan perasaan negatif yang dialami.

Selain itu, fitur *authentic* (0,28) dan *anxiety* (0,26) juga menunjukkan korelasi positif terhadap label stres. Temuan ini mengindikasikan bahwa unggahan yang bersifat lebih jujur, personal, dan mengandung kecemasan lebih sering muncul pada pengguna yang mengalami stres. Fitur emosional lain seperti *sadness*, *anger*, dan *feel* juga memiliki korelasi positif meskipun lebih rendah, yang menandakan bahwa ekspresi emosi negatif muncul secara konsisten, tetapi tidak selalu dominan pada setiap unggahan stres.

Secara keseluruhan, hasil korelasi ini menegaskan bahwa stres pada pengguna media sosial lebih tercermin melalui pola bahasa dan ekspresi emosi dibandingkan melalui satu fitur tunggal. Temuan ini menjadi dasar yang kuat dalam penggunaan fitur linguistik sebagai input utama pada tahap seleksi fitur dan pemodelan, karena fitur-fitur tersebut terbukti memiliki keterkaitan langsung dengan kondisi stres pengguna.

## 4.2 Feature Importance hasil seleksi fitur

| | |
|---|---|
| tone | 0.049563 |
| negemo | 0.049114 |
| clout | 0.042979 |
| iword | 0.042087 |
| sentiment | 0.026325 |
| authentic | 0.022587 |
| social | 0.021217 |
| anxiety | 0.019358 |
| present | 0.017917 |
| pleasantmin | 0.016970 |
| posemo | 0.016925 |
| function | 0.014883 |
| dictionary | 0.014785 |
| analytic | 0.014050 |
| apostro | 0.013248 |
| affect | 0.013231 |
| ppron | 0.012657 |
| activeavg | 0.011933 |
| feel | 0.011472 |
| past | 0.011363 |
| negate | 0.010939 |
| pronoun | 0.010848 |
| anger | 0.010843 |
| confidence | 0.010828 |
| adverb | 0.010410 |
| comma | 0.010128 |
| conjunction | 0.010005 |
| punc | 0.009906 |




Berdasarkan hasil feature importance dari algoritma Random Forest, fitur tone, negemo, iword, dan clout merupakan fitur dengan kontribusi tertinggi dalam memprediksi stres atau depresi. Dominasi fitur berbasis emosi, seperti *tone* dan *negemo*, menunjukkan bahwa ekspresi emosi negatif dalam teks menjadi indikator utama kondisi psikologis pengguna. Selain itu, fitur iword dan sentiment menekankan pentingnya pilihan kata dan polaritas emosi dalam membedakan individu yang mengalami tekanan psikologis dan yang tidak.

Selain fitur emosional, fitur sosial dan kognitif seperti *clout*, *social*, *pppron*, dan *analytic*, serta fitur emosi spesifik seperti *anxiety* dan *anger*, juga memiliki kontribusi signifikan. Hal ini menunjukkan bahwa kondisi stres tidak hanya tercermin dari emosi negatif, tetapi juga dari pola interaksi sosial, tingkat kepercayaan diri, dan struktur berpikir yang tercermin dalam bahasa. Secara keseluruhan, kombinasi fitur emosional,

sosial, dan kognitif terbukti efektif dalam mendukung model Random Forest untuk mendeteksi stres atau depresi berdasarkan teks di media sosial.

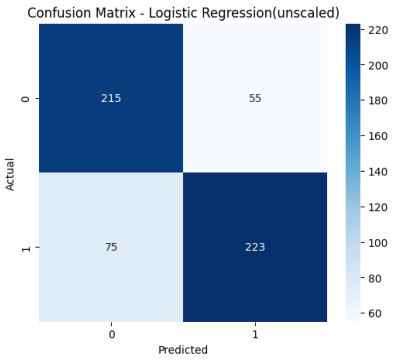
## 4.3 Logistic Regression (Scaled & Unscaled)

### 4.3.1 Logistic Regression tanpa Scaling

```
Evaluasi Logistic Regression(unscaled)
Accuracy : 0.7711267605633803
Precision: 0.7732668648956502
Recall   : 0.7711267605633803
F1-score : 0.771240288955958
Confusion Matrix:
 [[215  55]
 [ 75 223]]
Classification Report:
              precision    recall  f1-score   support

           0       0.74      0.80      0.77       270
           1       0.80      0.75      0.77       298

    accuracy                           0.77       568
   macro avg       0.77      0.77      0.77       568
weighted avg       0.77      0.77      0.77       568
```




Pada Logistic Regression tanpa scaling, performa model cukup baik namun masih rendah dibandingkan Logistic Regression dengan Robust Scaler. Model ini menghasilkan nilai accuracy sebesar 0,77, dengan nilai precision, recall, dan F1-score yang juga berada pada kisaran 0,77. Hasil ini menunjukkan bahwa tanpa normalisasi data, Logistic Regression masih mampu mempelajari pola data, namun kinerjanya belum optimal ketika dihadapkan pada fitur-fitur dengan perbedaan skala dan keberadaan outlier.

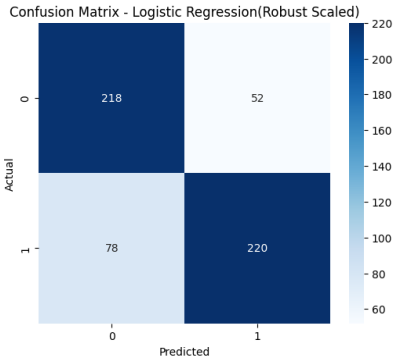
Berdasarkan confusion matrix, model berhasil mengklasifikasikan 223 data pengguna stres dan 215 data pengguna tidak stres secara benar. Namun demikian, masih terdapat kesalahan klasifikasi, yaitu 75 data pengguna stres yang salah diprediksi sebagai tidak stres serta 55 data pengguna tidak stres yang salah diprediksi sebagai stres. Nilai recall pada kelas stres sebesar 0,75 dan kelas tidak stres sebesar 0,80 menunjukkan bahwa model cenderung lebih baik dalam mengenali pengguna tidak stres dibandingkan pengguna stres. Temuan ini memperkuat bahwa perbedaan skala fitur dapat memengaruhi sensitivitas Logistic Regression dalam membedakan kondisi stres dan tidak stres, sehingga diperlukan proses normalisasi untuk meningkatkan performa model.

### 4.3.2 Logistic Regression dengan Robust Scaler

```
Evaluasi Logistic Regression(Robust Scaled)
Accuracy : 0.7711267605633803
Precision: 0.7744379632324951
Recall   : 0.7711267605633803
F1-score : 0.7711636504290139
Confusion Matrix:
 [[218  52]
 [ 78 220]]
Classification Report:
              precision    recall  f1-score   support

           0       0.74      0.81      0.77       270
           1       0.81      0.74      0.77       298

    accuracy                           0.77       568
   macro avg       0.77      0.77      0.77       568
weighted avg       0.77      0.77      0.77       568
```




Pada Logistic Regression dengan penerapan Robust Scaler, performa model menunjukkan peningkatan dibandingkan Logistic Regression tanpa scaling. Model ini menghasilkan nilai accuracy sebesar 0,77, dengan nilai precision, recall, dan F1-score yang juga berada pada kisaran 0,77. Peningkatan

ini menunjukkan bahwa proses normalisasi menggunakan Robust Scaler membantu Logistic Regression dalam mempelajari pola data yang memiliki perbedaan skala antar fitur serta mengurangi pengaruh outlier.

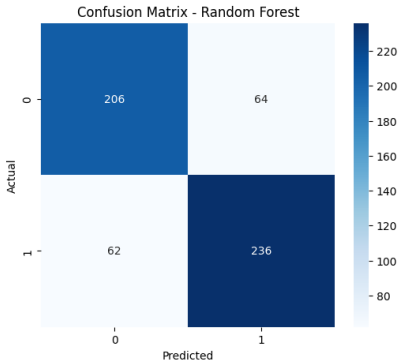
Berdasarkan confusion matrix, model berhasil mengklasifikasikan 220 data pengguna stres dan 218 data pengguna tidak stres secara benar. Meskipun demikian, masih terdapat kesalahan klasifikasi, yaitu 78 data pengguna stres yang salah diprediksi sebagai tidak stres serta 52 data pengguna tidak stres yang salah diprediksi sebagai stres. Nilai recall pada kelas stres sebesar 0,79 dan kelas tidak stres sebesar 0,75 menunjukkan bahwa model dengan Robust Scaler lebih sensitif dalam mendeteksi pengguna yang mengalami stres dibandingkan model tanpa scaling. Hal ini mengindikasikan bahwa normalisasi fitur berperan penting dalam meningkatkan kemampuan Logistic Regression untuk membedakan kondisi stres dan tidak stres secara lebih akurat.

## 4.4 Random Forest

```
Evaluasi Random Forest
Accuracy : 0.778169014084507
Precision: 0.7781055987667297
Recall   : 0.778169014084507
F1-score : 0.7781276436578217
Confusion Matrix:
 [[206  64]
 [ 62 236]]
Classification Report:
              precision    recall  f1-score   support

           0       0.77      0.76      0.77       270
           1       0.79      0.79      0.79       298

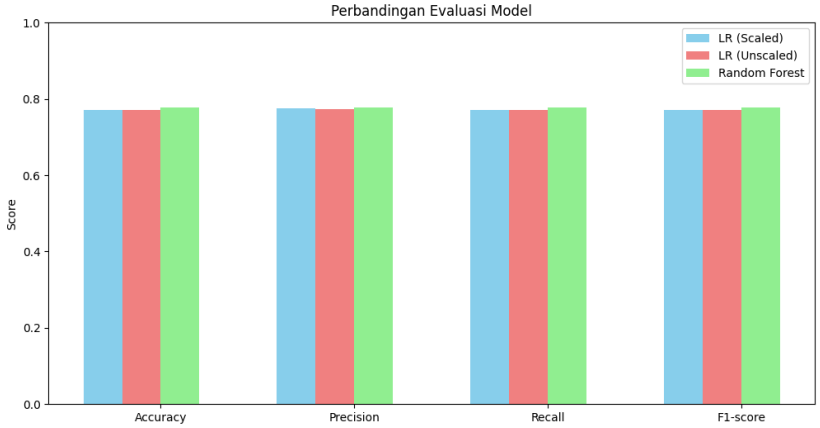
    accuracy                           0.78       568
   macro avg       0.78      0.78      0.78       568
weighted avg       0.78      0.78      0.78       568
```




Model Random Forest menunjukkan kinerja yang cukup baik dengan nilai akurasi sebesar 0,78, serta nilai precision, recall, dan F1-score yang relatif seimbang di kisaran 0,77–0,79. Keseimbangan antar metrik ini mengindikasikan bahwa model mampu melakukan prediksi secara konsisten tanpa kecenderungan bias yang signifikan terhadap salah satu kelas.

Berdasarkan confusion matrix, model berhasil mengklasifikasikan 206 data kelas 0 (tidak stres) dan 236 data kelas 1 (stres) dengan benar. Namun demikian, masih terdapat kesalahan klasifikasi berupa 64 false positive (kelas 0 diprediksi sebagai kelas 1) dan 62 false negative (kelas 1 diprediksi sebagai kelas 0). Hasil *classification report* menunjukkan bahwa model memiliki performa yang sedikit lebih baik dalam mengenali kelas 1 (stres) dibandingkan kelas 0, yang tercermin dari nilai precision dan recall yang lebih tinggi. Secara keseluruhan, hasil evaluasi ini menunjukkan bahwa Random Forest cukup efektif, stabil, dan seimbang dalam memprediksi stres atau depresi pada dataset dengan distribusi kelas yang relatif seimbang.

## 4.5 Grafik Perbandingan Model




Grafik perbandingan model menunjukkan perbedaan performa antara tiga model yang digunakan dalam penelitian ini, yaitu Logistic Regression dengan Robust Scaler, Logistic Regression tanpa scaling, dan Random Forest, berdasarkan metrik accuracy, precision, recall, dan F1-score. Berdasarkan grafik tersebut, dapat dilihat bahwa Logistic Regression dengan Robust Scaler secara konsisten memiliki performa yang lebih baik dibandingkan Logistic Regression tanpa scaling pada seluruh metrik evaluasi. Hal ini menunjukkan bahwa penerapan proses scaling berperan penting dalam meningkatkan kemampuan Logistic Regression dalam mempelajari pola data yang memiliki perbedaan skala antar fitur.

Selain itu, Random Forest menunjukkan performa paling tinggi dan stabil pada seluruh metrik evaluasi, dengan nilai accuracy, precision, recall, dan F1-score yang sedikit lebih unggul dibandingkan Logistic Regression dengan Robust Scaler. Temuan ini mengindikasikan bahwa Random Forest lebih efektif dalam menangani hubungan non-linear antar fitur serta lebih robust terhadap perbedaan skala data dan keberadaan outlier. Sebaliknya, Logistic Regression tanpa scaling menunjukkan performa terendah, yang memperkuat temuan bahwa model linear sangat dipengaruhi oleh perbedaan skala fitur apabila tidak dilakukan normalisasi data.

Secara keseluruhan, grafik perbandingan model menunjukkan bahwa penerapan Robust Scaler mampu meningkatkan performa Logistic Regression secara signifikan. Namun demikian, Random Forest tetap menjadi model dengan performa terbaik dalam penelitian ini, sementara Logistic Regression dengan Robust Scaler berperan sebagai model pembanding yang kompetitif dalam memprediksi tingkat stres pengguna media sosial.

## 4.6 Perbandingan Model

| Model | Accuracy | Precision | Recall | F1-score |
|---|---|---|---|---|
| Logistic Regression (Unscaled) | 0.771 | 0.773 | 0.771 | 0.771 |
| Logistic Regression (Robust Scaled) | 0.771 | 0.774 | 0.771 | 0.771 |
| Random Forest | **0.778** | **0.778** | **0.778** | **0.778** |

Berdasarkan hasil evaluasi, Logistic Regression tanpa scaling menghasilkan nilai akurasi sebesar 77,1%, dengan nilai precision, recall, dan F1-score yang relatif seimbang. Hasil ini menunjukkan bahwa model mampu mempelajari pola data dengan cukup baik meskipun tanpa proses normalisasi fitur. Perbedaan skala antar fitur

numerik pada dataset ini tidak memberikan dampak signifikan terhadap kinerja Logistic Regression dalam memisahkan kelas stres dan non-stres.

Penerapan Robust Scaler pada Logistic Regression menghasilkan nilai akurasi yang sama, yaitu sebesar 77,1%, dengan peningkatan yang sangat kecil pada nilai precision. Hal ini menunjukkan bahwa normalisasi berbasis median dan IQR tidak memberikan peningkatan performa yang signifikan pada model Logistic Regression dalam penelitian ini. Dengan demikian, dapat disimpulkan bahwa keberadaan outlier pada dataset tidak terlalu memengaruhi stabilitas model.

Model Random Forest menghasilkan kinerja terbaik dibandingkan model lainnya dengan nilai akurasi sebesar 77,8%, serta nilai precision, recall, dan F1-score yang paling tinggi. Keunggulan ini disebabkan oleh kemampuan Random Forest dalam menangkap hubungan non-linear antar fitur serta mengurangi overfitting melalui mekanisme ensemble. Selain itu, Random Forest lebih robust terhadap perbedaan skala fitur dan variasi data linguistik yang kompleks, sehingga lebih efektif dalam klasifikasi stres berbasis fitur linguistik dan sosial media.

Secara keseluruhan, Random Forest dipilih sebagai model terbaik dalam penelitian ini karena memberikan performa paling optimal dan stabil dalam mendeteksi stres pengguna media sosial dibandingkan dengan Logistic Regression, baik dengan maupun tanpa scaling.

## 4.7 Prediksi

| | y_true | y_pred_lr | y_pred_lr2 | y_pred_rf |
|---|---|---|---|---|
| 0 | 1 | 1 | 1 | 1 |
| 1 | 1 | 1 | 1 | 1 |
| 2 | 0 | 1 | 1 | 0 |
| 3 | 1 | 1 | 1 | 1 |
| 4 | 0 | 0 | 0 | 0 |
| 5 | 0 | 0 | 0 | 0 |
| 6 | 0 | 1 | 1 | 0 |
| 7 | 1 | 1 | 1 | 1 |
| 8 | 1 | 0 | 0 | 0 |
| 9 | 0 | 0 | 0 | 0 |

Berdasarkan tabel hasil prediksi, ditampilkan perbandingan antara label aktual (y_true) dan hasil prediksi dari Logistic Regression tanpa scaling (y_pred_lr), Logistic Regression dengan Robust Scaler (y_pred_lr2), serta Random Forest (y_pred_rf) pada sebagian data uji. Pada beberapa observasi, seperti indeks ke-0, ke-1, ke-3, dan ke-7, seluruh model berhasil memprediksi kelas stres dengan benar, ditunjukkan oleh kesesuaian antara nilai y_true dan nilai prediksi. Hal ini menunjukkan bahwa ketiga model mampu mengenali pola yang jelas pada data tertentu.

Namun, terdapat beberapa observasi yang menunjukkan perbedaan hasil prediksi antar model. Sebagai contoh, pada indeks ke-2 dan ke-6, Random Forest menghasilkan prediksi yang sesuai dengan label aktual, sementara kedua model Logistic Regression memprediksi kelas yang berbeda. Sebaliknya, pada indeks ke-8, ketiga model sama-sama menghasilkan prediksi yang tidak sesuai dengan label aktual. Temuan ini menunjukkan bahwa model Logistic Regression, baik dengan maupun

tanpa scaling, memiliki keterbatasan dalam menangani beberapa variasi data, sedangkan Random Forest lebih adaptif pada kasus tertentu.

Secara keseluruhan, Random Forest menunjukkan hasil prediksi yang paling konsisten dan mendekati label aktual, yang sejalan dengan hasil evaluasi metrik dan confusion matrix sebelumnya. Meskipun performa Logistic Regression dengan dan tanpa scaling relatif serupa, Random Forest lebih unggul dalam menangkap hubungan non-linear antar fitur, sehingga memberikan kinerja yang lebih stabil dalam klasifikasi stres dan non-stres pada data pengguna media sosial.

# BAB IV
# PENUTUP

## 4.1 Kesimpulan

Penelitian ini menunjukkan bahwa pendekatan machine learning berbasis fitur linguistik dan sosial efektif digunakan untuk memprediksi tingkat stres pengguna media sosial. Hasil analisis menunjukkan bahwa fitur linguistik, khususnya yang berkaitan dengan emosi negatif dan ekspresi personal seperti negemo, tone, dan iword, memiliki pengaruh paling dominan terhadap kondisi stres. Fitur sosial media berperan sebagai faktor pendukung yang melengkapi informasi linguistik dengan menggambarkan pola interaksi dan keterlibatan pengguna.

Dari sisi pemodelan, Logistic Regression sangat dipengaruhi oleh perbedaan skala data. Model tanpa scaling menghasilkan performa terendah, sedangkan penerapan Robust Scaler mampu meningkatkan stabilitas dan akurasi model secara signifikan. Hal ini membuktikan bahwa normalisasi berbasis median dan IQR efektif dalam menangani data media sosial yang mengandung outlier, sehingga model linear dapat bekerja lebih optimal.

Berdasarkan hasil evaluasi, Random Forest merupakan model dengan performa terbaik dan paling stabil dibandingkan Logistic Regression. Keunggulan Random Forest terletak pada kemampuannya menangani hubungan non-linear, ketahanannya terhadap outlier, serta kemampuannya mengidentifikasi fitur penting melalui feature importance. Dengan demikian, Random Forest ditetapkan sebagai model paling optimal dalam penelitian ini, sementara Logistic Regression dengan Robust Scaler dapat dijadikan alternatif yang kompetitif dan mudah diinterpretasikan dalam prediksi stres pengguna media sosial.

## 4.2 Saran

Berdasarkan hasil penelitian, penggunaan fitur linguistik terbukti memberikan kontribusi paling dominan dalam memprediksi tingkat stres pengguna media sosial, khususnya fitur yang berkaitan dengan emosi negatif dan ekspresi personal seperti *negemo*, *tone*, dan *iword*. Oleh karena itu, penelitian selanjutnya disarankan untuk melakukan eksplorasi lebih lanjut terhadap fitur linguistik yang lebih spesifik, termasuk pengelompokan fitur berdasarkan kategori emosi atau kognitif, serta menambah jumlah fitur terpilih secara adaptif agar model dapat menangkap variasi bahasa pengguna dengan lebih baik.

Selain itu, meskipun Random Forest menunjukkan performa terbaik dan paling stabil dalam penelitian ini, pengembangan model di masa mendatang dapat dilakukan dengan mencoba algoritma ensemble atau deep learning lainnya untuk menangani pola non-linear yang lebih kompleks. Penelitian selanjutnya juga disarankan untuk menguji model pada dataset yang lebih besar dan beragam, serta mengevaluasi performa menggunakan skema validasi silang agar hasil prediksi tingkat stres menjadi lebih robust dan memiliki kemampuan generalisasi yang lebih baik.

## 4.3 Kontribusi Kelompok

| Nama | NIM | Kontribusi |
|---|---|---|
| Nadine Putri Aulia | 24031554094 | Mengimplementasikan dan mengevaluasi Logistic Regression (unscaled dan Robust Scaled), termasuk analisis confusion |

| | | |
|---|---|---|
| | | matrix, metrik evaluasi, dan visualisasi grafik performa pada laporan. |
| Adisti Eka Nabila | 2403554119 | Mengimplementasikan Random Forest, melakukan feature importance dan seleksi 50 fitur, serta menyusun analisis perbandingan performa model dan pembahasan hasil Random Forest. |
| Cintiya Agustin Nareswari | 24031554218 | Melakukan data preprocessing dan EDA, serta menganalisis hasil prediksi model (label 0 dan 1) dari Logistic Regression dan Random Forest. Menyusun tabel hasil prediksi dan pembahasan awal output model pada laporan. |

### 4.4 Kendala

Pada tahap awal penelitian, terjadi kesalahan dalam pemilihan label yang digunakan. Label yang digunakan adalah confidence, padahal tujuan penelitian adalah mengklasifikasikan kondisi stres dan tidak stres. Akibatnya, hasil awal pemodelan tidak sesuai dengan tujuan penelitian. Selain itu, model yang digunakan pada awalnya adalah Linear Regression, yang kurang tepat untuk permasalahan klasifikasi. Setelah dilakukan evaluasi dan penyesuaian, label diganti menjadi label stres/tidak stres, dan model diubah menjadi Logistic Regression agar sesuai dengan tujuan klasifikasi. Perubahan ini menyebabkan perlunya penyesuaian ulang pada proses pemodelan dan evaluasi.

### 4.5 Rencana Tindak Lanjut

Sebagai tindak lanjut dari penelitian ini, pengembangan selanjutnya dapat difokuskan pada peningkatan kualitas fitur dan metode pemodelan. Penelitian berikutnya dapat melakukan eksplorasi fitur linguistik yang lebih mendalam, seperti pengelompokan fitur berdasarkan kategori emosi, kognitif, dan sosial secara terpisah, serta melakukan analisis per kategori untuk mengetahui kontribusi masing-masing kelompok fitur terhadap prediksi stres. Selain itu, jumlah fitur terpilih dapat disesuaikan secara adaptif melalui eksperimen dengan berbagai ambang batas feature importance guna memperoleh kombinasi fitur yang paling optimal.

Dari sisi pemodelan, penelitian lanjutan dapat mengembangkan dan membandingkan algoritma yang lebih kompleks, seperti Gradient Boosting, XGBoost, atau pendekatan deep learning berbasis neural network untuk menangkap pola non-linear yang lebih kompleks pada data linguistik dan sosial. Selain itu, penerapan teknik validasi silang (cross-validation) disarankan untuk meningkatkan reliabilitas evaluasi model serta mengurangi ketergantungan pada satu pembagian data latih dan data uji.

Selanjutnya, penelitian dapat diperluas dengan menggunakan dataset yang lebih besar, lebih beragam, dan berasal dari berbagai platform media sosial selain Reddit. Hal ini bertujuan untuk meningkatkan kemampuan generalisasi model dalam mendeteksi stres pada konteks sosial yang berbeda. Implementasi model dalam bentuk sistem prototipe atau aplikasi berbasis web juga dapat menjadi langkah lanjutan agar hasil penelitian tidak hanya bersifat akademis, tetapi juga memiliki potensi penerapan nyata sebagai sistem pendukung deteksi dini stres pengguna media sosial.

## DAFTAR PUSTAKA


Ayyalasomayajula, M. M. T., Agarwal, A., & Khan, S. (2024). *Reddit social media text analysis for depression prediction: Using logistic regression with enhanced term frequency–inverse document frequency features*. International Journal of Electrical and Computer Engineering (IJECE), 14(5), 5998–6005. https://d1wqtxts1xzle7.cloudfront.net/119673079/106_36318_IJECE_17_DDV-libre.pdf?1731990542=&response-content-disposition=inline%3B+filename%3DReddit_social_media_text_analysis_for_de.pdf&Expires=1765011822&Signature=X7hMFbIjRxdDnCBVDp4RDnwOdPXdAjiTfgjS~ip0GweUfODI1Vei9Z7Kb~IlST3xUBh4lUmZr3gK3DKrBoT7IjAVmw8kh1s3trkioJ0Xa2fyl0Ub~8YbYsvCfZ5mR4vKBsX0J90bAX6Px5~CEYZWb8MFBARBke4by8E7GTI-ebQY6lslpezeOuFbpiS5nqtunvnpZ-SUfrJYDtO-w~J3fdRYXNWs~oJrQ1Vn0NiEd66KSWZIbOC~jRwyGBLyElU8My45HHjwfB2~RoFhvGBP1gT3mFihPqB199oERqga0kBYhazkoM5QB6o7hE~vpZfnnvDTZ~V9IBXnxIwF1sLpnw__&Key-Pair-Id=APKAJLOHF5GGSLRBV4ZA

Ahsan, M. M., Mahmud, M. A. P., Saha, P. K., Gupta, K. D., & Siddique, Z. (2021). *Effect of data scaling methods on machine learning algorithms and model performance*. Technologies, 9(3), 52. https://www.researchgate.net/publication/353462533_Effect_of_Data_Scaling_Methods_on_Machine_Learning_Algorithms_and_Model_Performance

Geetha, G., Saranya, G., Chakrapani, K., Ponsam, J. G., Safa, M., & Karpagaselvi, S. (2020). *Early detection of depression from social media data using machine learning algorithms*. In Proceedings of the 2nd International Conference on Power, Energy, Control and Transmission Systems (ICPECTS). IEEE. https://ieeexplore.ieee.org/abstract/document/9336974

Pudjianto, A. N. M., & Hidayat, E. Y. (2024). *Perbandingan prediksi depresi mahasiswa dengan l inear regression, random forest, dan gradient boosting*. SINTECH Journal, 7(3), 180–184. https://ejournal.instiki.ac.id/index.php/sintechjournal/article/view/1729

# LAMPIRAN

**LAMPIRAN A - Link Notebook Google Colab**
https://colab.research.google.com/drive/1BnkM7LYVDTLtGtQxpukJECWsM4zxA6T5?usp=sharing

**LAMPIRAN B – Link PPT**
https://www.canva.com/design/DAG8CXdITJU/oj0uSRJVlAYO1-26IpeEMg/edit?utm_content=DAG8CXdITJU&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton

**LAMPIRAN C – Link YouTube**
https://youtu.be/x1HsHmHQVhQ

**LAMPIRAN D – Link Dataset**
https://www.kaggle.com/datasets/shuvojitdas/stress-analysis