Universitas Negeri Surabaya

PREDIKSI STRES PADA PENGGUNA MEDIA SOSIAL MENGGUNAKAN LOGISTIC REGRESSION DAN RANDOM FOREST BERBASIS FITUR LINGUISTIK DAN SOSIAL



Dosen Pengampu:

- Riskyana Dewi Intan P, M.Kom.
- Yuni Rosita Dewi, S.Si., M.Si.

Universitas Negeri Surabaya

Our Team



Nadine Putri Aulia
24031554094



Adisti Eka Nabila
24031554119



Cintiya Agustin Nareswari
24031554218

Latar Belakang

Media sosial menjadi sarana utama bagi individu untuk mengekspresikan emosi dan kondisi psikologis melalui teks secara terbuka, sehingga unggahan dan komentar pengguna dapat mencerminkan tingkat stres yang dialami. Pola bahasa, pilihan kata, serta ekspresi emosional dalam teks media sosial dapat dianalisis menggunakan pendekatan machine learning melalui pemanfaatan fitur linguistik, seperti emosi positif dan negatif serta kompleksitas bahasa. Selain itu, karakteristik interaksi sosial pengguna, seperti karma, rasio upvote, dan jumlah komentar, juga berpotensi memberikan informasi tambahan terkait respons sosial dan keterlibatan pengguna. Dalam penelitian ini, digunakan algoritma Logistic Regression dan Random Forest untuk memprediksi tingkat stres pengguna, dengan tujuan membandingkan performa kedua model serta mengidentifikasi fitur yang paling berpengaruh melalui analisis feature importance pada Random Forest.

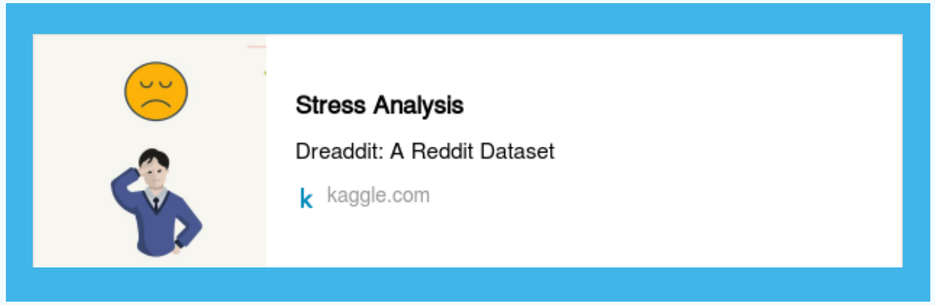
Rumusan Masalah

- Bagaimana pengaruh fitur linguistik terhadap tingkat stres pengguna media sosial?
- Seberapa besar kontribusi fitur sosial media dalam memprediksi tingkat stres?
- Model mana yang memiliki performa terbaik dalam prediksi tingkat stres, Logistic Regression atau Random Forest Classifier?
- Fitur mana yang paling berpengaruh terhadap prediksi tingkat stres berdasarkan feature importance Random Forest?

Tujuan

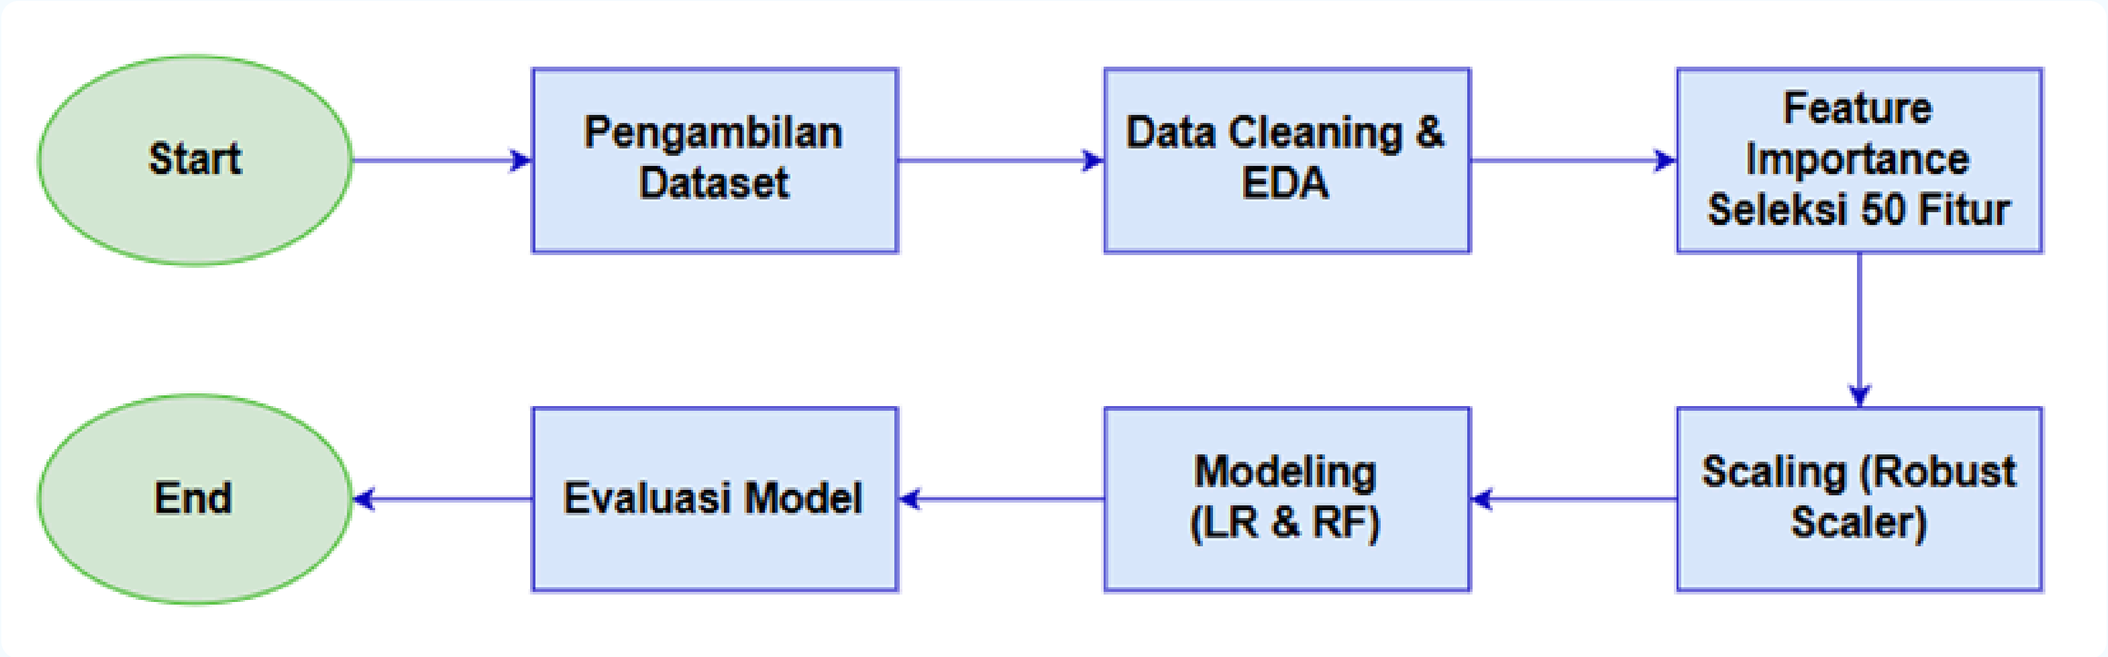
- Menganalisis pengaruh fitur linguistik terhadap tingkat stres pengguna media sosial.
- Mengukur kontribusi fitur sosial media dalam prediksi tingkat stres.
- Membandingkan performa model Logistic Regression dan Random Forest Classifier dalam prediksi tingkat stres.
- Mengidentifikasi fitur paling berpengaruh berdasarkan feature importance Random Forest Classifier.

Deskripsi Dataset



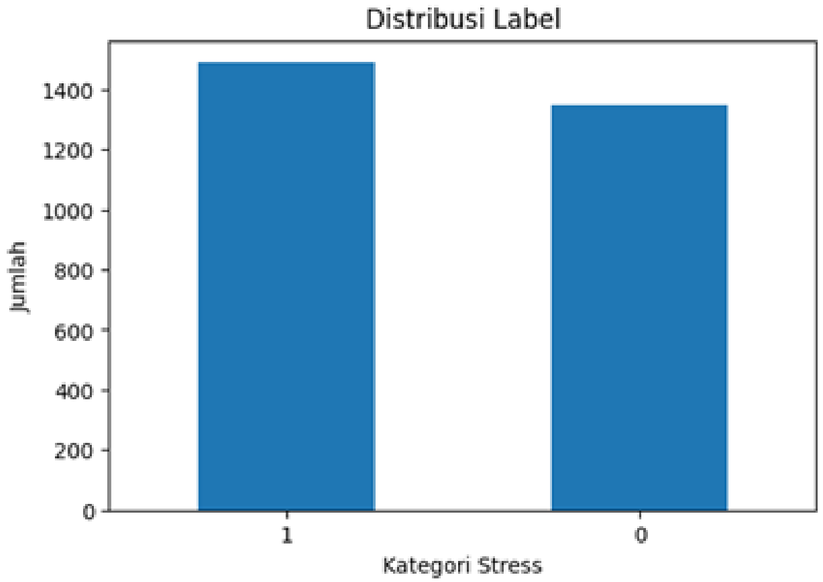
- Dataset ini diambil dari Stress Analysis Dataset di Kaggle
- Digunakan untuk mempelajari hubungan antara ekspresi bahasa dan tingkat stres
- Dataset berisi teks postingan media sosial beserta fitur numerik yang diekstraksi
- Semua fitur adalah hasil pemrosesan linguistik (LIWC, DAL, sintaks) dan sosial (karma, komentar, upvote)
- Setiap baris mewakili satu entri postingan dengan label stres atau tidak stres
- Total data sekitar 2838 entri
- Label target: 1 = stres, 0 = tidak stres

Alur Project



Exploratory Data Analysis

Distribusi Label Stres

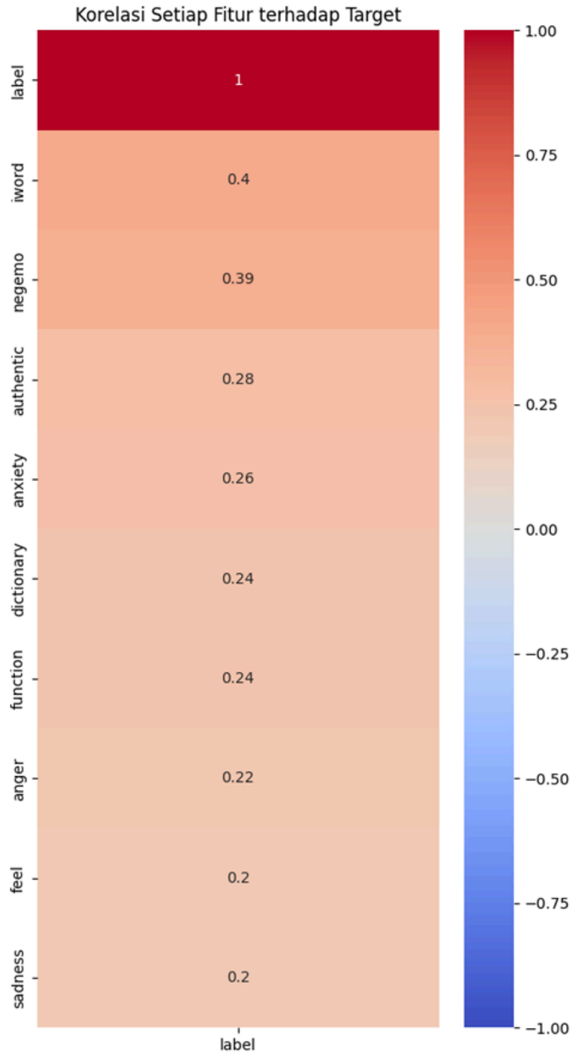


- Label stres (1) lebih banyak dibandingkan tidak stres (0)
- Selisih jumlah data tidak terlalu besar
- Distribusi data cukup seimbang
- Kondisi ini tidak menimbulkan bias ekstrem pada model

Top 10 Kolom dengan Outlier Terbanyak



- Kolom qmark memiliki jumlah outlier tertinggi dibandingkan fitur lain. Kolom dash dan ingest menempati urutan berikutnya dengan jumlah outlier yang juga tinggi.
- Fitur imagerymax dan netspeak menunjukkan jumlah outlier yang cukup signifikan.
- Outlier paling banyak muncul pada 10 fitur teratas yang ditampilkan pada grafik.
- Kondisi ini menunjukkan bahwa beberapa fitur memiliki sebaran data yang tidak merata.



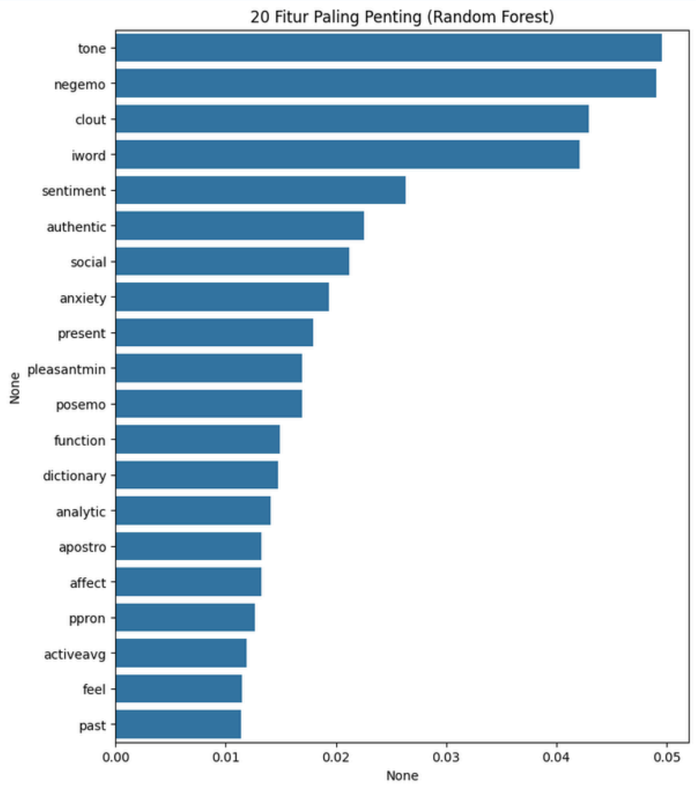
Exploratory Data Analysis

Korelasi Fitur terhadap Label Stres

- Fitur word memiliki korelasi tertinggi terhadap label (0,40).
- Fitur negemo juga menunjukkan korelasi cukup kuat (0,39).
- Fitur authentic dan anxiety memiliki korelasi sedang (0,28 dan 0,26).
- Fitur dictionary dan function menunjukkan korelasi yang relatif rendah (0,24).
- Fitur anger, feel, dan sadness memiliki korelasi paling lemah (≤ 0,22).
- Secara umum, seluruh fitur memiliki korelasi positif, namun tidak ada yang sangat dominan.

Feature Importance

tone	0.049563
negemo	0.049114
clout	0.042979
iword	0.042087
sentiment	0.026325
authentic	0.022587
social	0.021217
anxiety	0.019358
present	0.017917
pleasantmin	0.016970
posemo	0.016925
function	0.014883
dictionary	0.014785
analytic	0.014050
apostro	0.013248
affect	0.013231
ppron	0.012657
activeavg	0.011933
feel	0.011472
past	0.011363
negate	0.010939
pronoun	0.010848
anger	0.010843
confidence	0.010828
adverb	0.010410
comma	0.010128
conjunction	0.010005
punc	0.009906



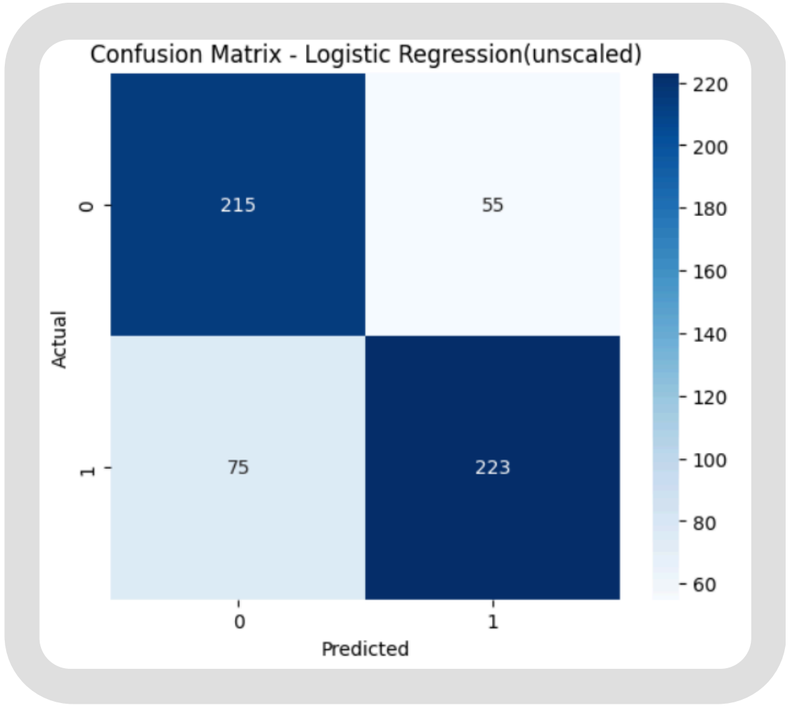
Hasil feature importance Random Forest menunjukkan bahwa fitur emosional seperti tone dan negemo merupakan indikator utama dalam memprediksi stres atau depresi. Fitur iword dan sentiment turut menegaskan peran pilihan kata dan polaritas emosi dalam membedakan kondisi psikologis pengguna.
Selain itu, fitur sosial dan kognitif seperti clout, social, pppron, analytic, serta emosi spesifik seperti anxiety dan anger memperkuat bahwa kombinasi aspek emosional, sosial, dan kognitif paling efektif dalam mendeteksi stres atau depresi pada teks media sosial.

Evaluasi Model-Logistic Regression tanpa Scaling

```
Evaluasi Logistic Regression(unscaled)
Accuracy : 0.7711267605633803
Precision: 0.7732668648956502
Recall   : 0.7711267605633803
F1-score : 0.771240288955958
Confusion Matrix:
 [[215  55]
 [ 75 223]]
Classification Report:
              precision    recall  f1-score   support

           0       0.74      0.80      0.77       270
           1       0.80      0.75      0.77       298

    accuracy                           0.77       568
   macro avg       0.77      0.77      0.77       568
weighted avg       0.77      0.77      0.77       568
```



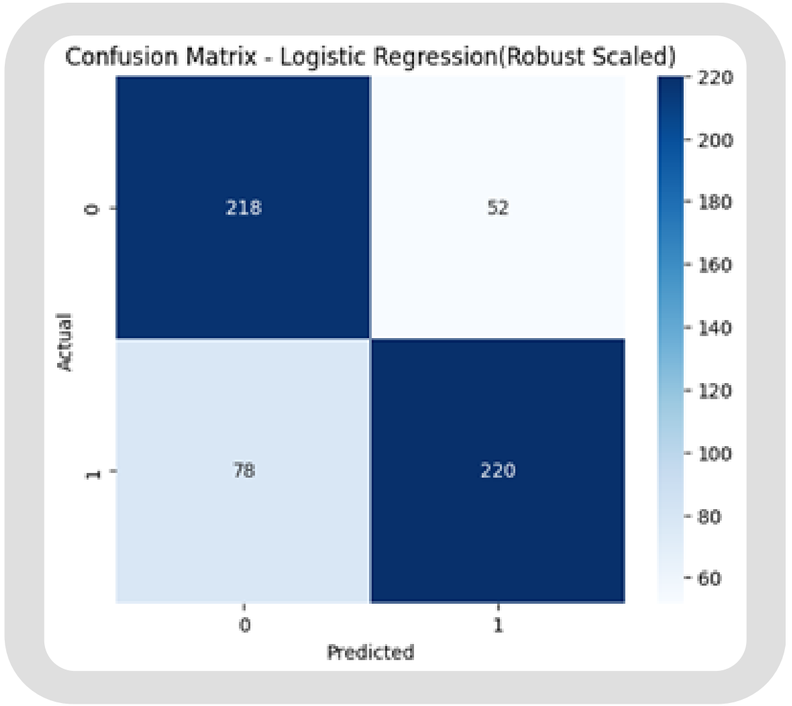
- Performa model cukup baik dengan accuracy 0,77, serta nilai precision, recall, dan F1-score yang relatif seimbang.
- Hasil klasifikasi menunjukkan model lebih baik dalam mengenali pengguna tidak stres (recall 0,80) dibandingkan pengguna stres (recall 0,75), dengan masih terdapat kesalahan prediksi pada kedua kelas.

Evaluasi Model-Logistic Regression (Robust Scaled)

```
Evaluasi Logistic Regression(Robust Scaled)
Accuracy : 0.7711267605633803
Precision: 0.7744379632324951
Recall   : 0.7711267605633803
F1-score : 0.7711636504290139
Confusion Matrix:
 [[218  52]
 [ 78 220]]
Classification Report:
              precision    recall  f1-score   support

           0       0.74      0.81      0.77       270
           1       0.81      0.74      0.77       298

    accuracy                           0.77       568
   macro avg       0.77      0.77      0.77       568
weighted avg       0.77      0.77      0.77       568
```



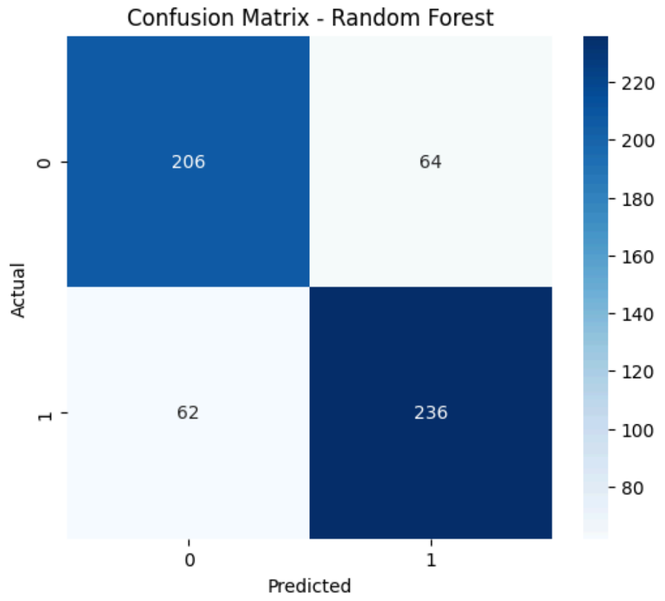
- Performa meningkat dengan accuracy 0,77 serta nilai precision, recall, dan F1-score yang relatif seimbang, menunjukkan model mampu mempelajari pola data dengan lebih baik setelah normalisasi.
- Hasil klasifikasi menunjukkan model lebih sensitif dalam mendeteksi pengguna stres (recall 0,79) dibandingkan pengguna tidak stres (recall 0,75), meskipun masih terdapat kesalahan prediksi pada kedua kelas.

Evaluasi Model-Random Forest

```
Evaluasi Random Forest
Accuracy : 0.778169014084507
Precision: 0.7781055987667297
Recall   : 0.778169014084507
F1-score : 0.7781276436578217
Confusion Matrix:
 [[206  64]
 [ 62 236]]
Classification Report:
              precision    recall  f1-score   support

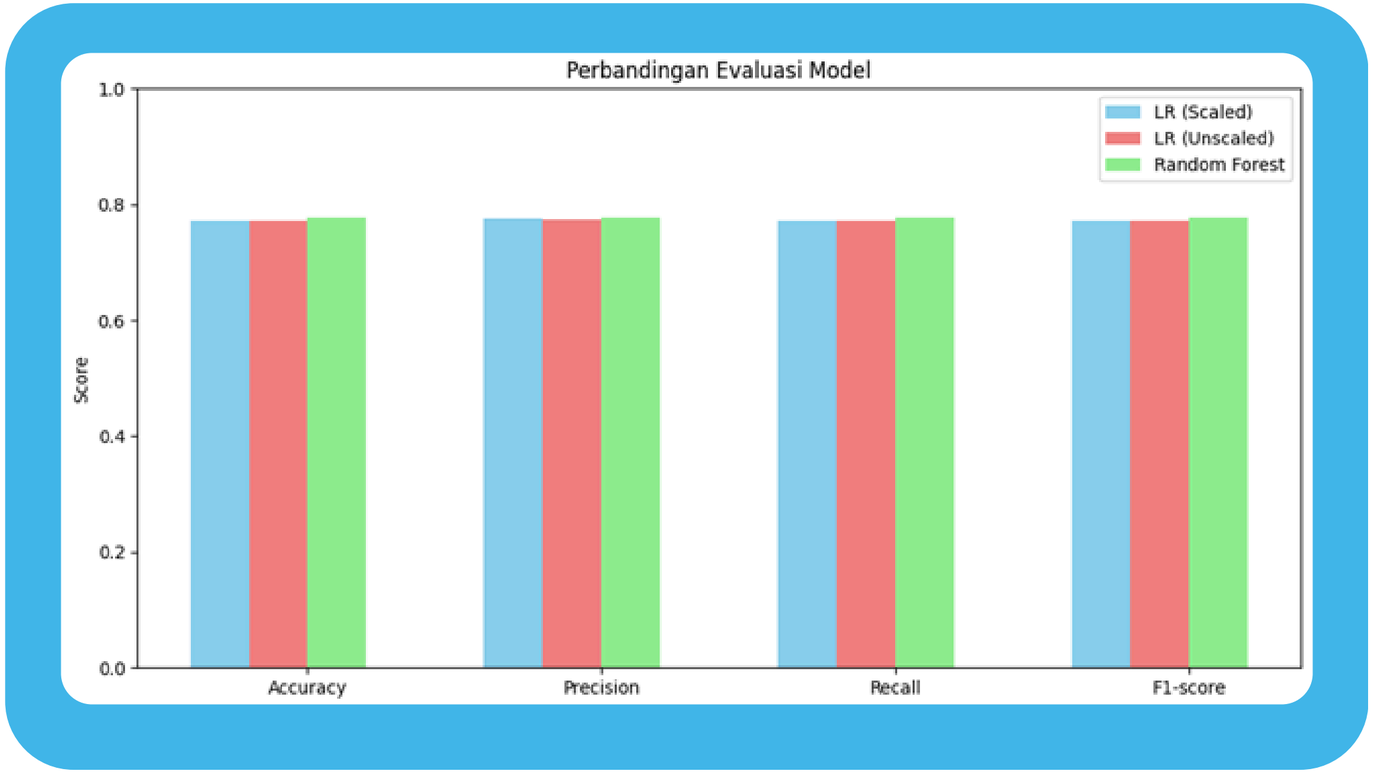
           0       0.77      0.76      0.77       270
           1       0.79      0.79      0.79       298

    accuracy                           0.78       568
   macro avg       0.78      0.78      0.78       568
weighted avg       0.78      0.78      0.78       568
```



- Random Forest menunjukkan kinerja yang baik dan stabil dengan akurasi sebesar 78%, serta nilai precision, recall, dan F1-score yang relatif seimbang di kisaran 0,77–0,79, menandakan bahwa model tidak bias dan mampu mengklasifikasikan sebagian besar data dengan benar.
- Model ini juga lebih efektif dalam mengenali kelas stres/depresi (kelas 1) dibandingkan kelas tidak stres, dengan tingkat kesalahan klasifikasi yang masih relatif terkendali.

Grafik Perbandingan Model



- Logistic Regression dengan Robust Scaler menunjukkan performa lebih baik dibandingkan tanpa scaling pada seluruh metrik evaluasi.
- Random Forest memiliki performa paling tinggi dan stabil, serta lebih robust terhadap hubungan non-linear dan perbedaan skala fitur.
- Robust Scaler meningkatkan performa Logistic Regression, namun Random Forest tetap menjadi model terbaik.

Perbandingan & Hasil Prediksi

Model	Accuracy	Precision	Recall	F1-score
Logistic Regression (Unscaled)	0.771	0.773	0.771	0.771
Logistic Regression (Robust Scaled)	0.771	0.774	0.771	0.771
Random Forest	**0.778**	**0.778**	**0.778**	**0.778**

- Logistic Regression (unscaled & scaled) memiliki performa hampir sama (accuracy 77,1%).
- Robust Scaler tidak memberi peningkatan signifikan.
- Random Forest memiliki performa tertinggi (accuracy 77,8%).
- Random Forest dipilih sebagai model terbaik.

	y_true	y_pred_lr	y_pred_lr2	y_pred_rf
0	1	1	1	1
1	1	1	1	1
2	0	1	1	0
3	1	1	1	1
4	0	0	0	0
5	0	0	0	0
6	0	1	1	0
7	1	1	1	1
8	1	0	0	0
9	0	0	0	0

- y_pred_lr dan y_pred_lr2 menunjukkan prediksi Logistic Regression.
- y_pred_rf menunjukkan prediksi Random Forest.
- Terlihat bahwa pada sebagian besar data, semua model memberikan prediksi yang sama dengan label aktual.
- Pada beberapa kasus, Logistic Regression menghasilkan prediksi yang keliru, sedangkan Random Forest tetap konsisten.

Kesimpulan

Penelitian ini menunjukkan bahwa pendekatan machine learning berbasis fitur linguistik dan sosial efektif dalam memprediksi stres pengguna media sosial, dengan fitur linguistik khususnya emosi negatif dan ekspresi personal seperti negemo, tone, dan iword sebagai faktor paling dominan, sementara fitur sosial berperan sebagai pendukung. Logistic Regression terbukti sensitif terhadap perbedaan skala data, di mana penerapan Robust Scaler mampu meningkatkan stabilitas dan akurasi model secara signifikan. Berdasarkan hasil evaluasi, Random Forest menjadi model paling optimal dan stabil karena mampu menangani hubungan non-linear, tahan terhadap outlier, serta menyediakan informasi feature importance, sehingga unggul dalam prediksi stres pengguna media sosial.

Universitas Negeri Surabaya

Referensi

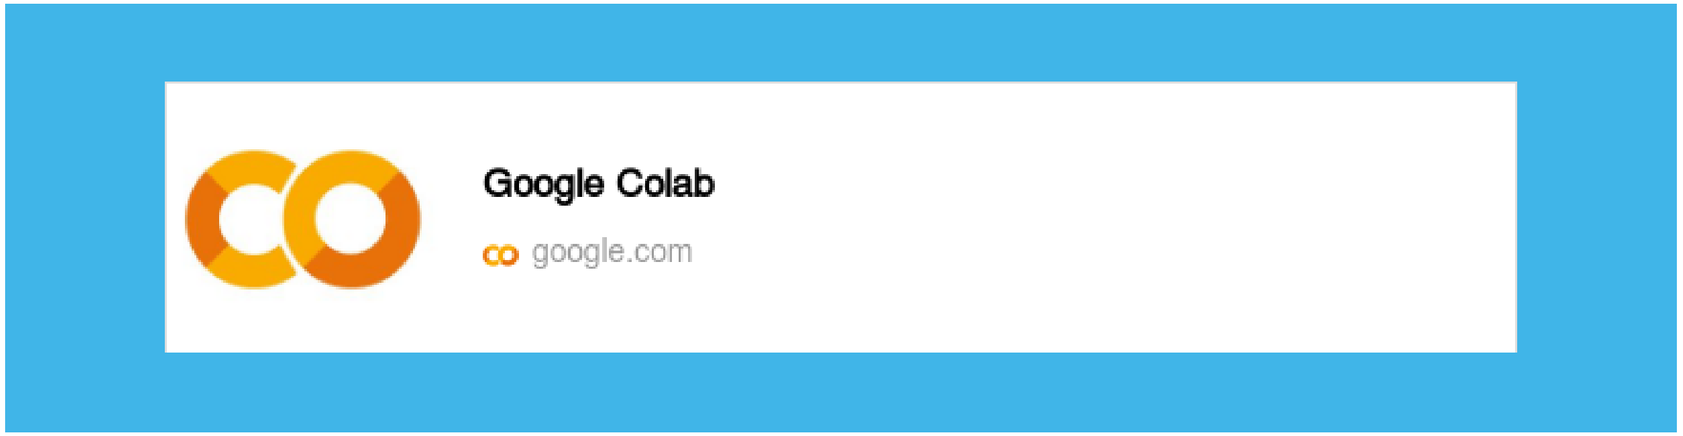
Reddit social media text analysis for depression prediction: Using logistic regression with enhanced term frequency–inverse document frequency features. https://d1wqtxts1xzle7.cloudfront.net/119673079/106_36318_IJECE_17_DDV-libre.pdf?1731990542=&response-content-disposition=inline%3B+filename%3DReddit_social_media_text_analysis_for_de.pdf&Expires=1765011822&Signature=X7hMFbIjRxdDnCBVDp4RDnwOdPXdAjiTfgjS~ip0GweUfODI1Vei9Z7Kb~IlST3xUBh4lUmZr3gK3DKrBoT7IjAVmw8kh1s3trkioJ0Xa2fyl0Ub~8YbYsvCfZ5mR4vKBsX0J90bAX6Px5~CEYZWb8MFBARBke4by8E7GTI-ebQY6lslpezeOuFbpiS5nqtunvnpZ-SUfrJYDtO-w~J3fdRYXNWs~oJrQ1Vn0NiEd66KSWZIbOC~jRwyGBLyElU8My45HHjwfB2~RoFhvGBP1gT3mFihPqB199oERqga0kBYhazkoM5QB6o7hE~vpZfnnvDTZ~V9IBXnxlwF1sLpnw__&Key-Pair-Id=APKAJLOHF5GGSLRBV4ZA

Effect of data scaling methods on machine learning algorithms and model performance. https://www.researchgate.net/publication/353462533_Effect_of_Data_Scaling_Methods_on_Machine_Learning_Algorithms_and_Model_Performance

Early detection of depression from social media data using machine learning algorithms. In Proceedings of the 2nd International Conference on Power, Energy, Control and Transmission Systems (ICPECTS). https://ieeexplore.ieee.org/abstract/document/9336974

Perbandingan prediksi depresi mahasiswa dengan linear regression, random forest, dan gradient boosting. https://ejournal.instiki.ac.id/index.php/sirtech/article/view/1729

TAUTAN GOOGLE COLAB



Universitas Negeri Surabaya



We appreciate your time and attention.

Let’s Build Something Great Together
If you have questions or want to explore this further, we’re ready to talk.